

BLM308 Veri Madenciliđi Final Projesi

3D Yazıcı Dilimleme Parametreleri ile Üretim Öncesi Baskı Kalitesi ve
Hata Tahmini: Uçtan Uca CRISP-DM Analizi

Emirhan Gürsoy

221041054

Bilgisayar Mühendisliđi Bölümü

Bahar Dönemi, 2026

İçindekiler

1	Özet (Abstract)	3
2	İş Gereksinimlerinin Anlaşılması (Business Understanding)	4
2.1	Problem Tanımı ve Sektörel Arka Plan	4
2.2	Veri Madenciliği Hedefleri ve CRISP-DM Yaklaşımı	4
2.3	Teknik ve Ticari Başarı Kriterleri	4
3	Verinin Anlaşılması (Data Understanding)	5
3.1	Veri Kaynağı ve Toplama Stratejisi	5
3.2	Veri Sözlüğü (Feature Matrix)	5
3.3	Özellikler Arasındaki Fiziksel İlişkiler ve Keşifsel Analiz	5
4	Veri Ön İşleme (Data Preparation)	6
4.1	Eksik Verilerin Tahmin Edilmesi (Median Imputation)	6
4.2	Kategorik Değişkenlerin Sayısallaştırılması (One-Hot Encoding)	6
4.3	Özellik Ölçeklendirme ve Standardizasyon	6
4.4	Veri Sızıntısının (Data Leakage) Engellenmesi	6
5	Modelleme (Modeling)	7
5.1	Lojistik Regresyon (Logistic Regression)	7
5.2	Karar Ağacı (Decision Tree Classifier)	7
5.3	Rastgele Orman (Random Forest Classifier)	7
6	Değerlendirme ve Deney Sonuçları (Evaluation)	8
6.1	Performans Metriklerinin Karşılaştırılması	8
6.2	Karmaşıklık Matrisi (Confusion Matrix) Çıktıları	8
6.3	Sonuçların Akademik ve Teknik Analizi	8
6.4	Derinlemesine Mühendislik Hata Analizi (Kritik Bulgular)	8
7	Canlandırma ve Dağıtım (Deployment)	10
7.1	Streamlit Kontrol Paneli Mimarisi	10
7.2	Plotly Grafik Entegrasyonu ve Geometrik Filtreler	10
8	Bonus Puan Talepleri ve Teknik Gerekçeleri	10

1 Özet (Abstract)

Bu çalışmada, katmanlı üretim (3D Printing) süreçlerinde karşılaşılan baskı arızalarının (parça kalkması, nozül tıkanması, spagetti ve aşırı ipliklenme) üretim başlamadan önce tahmin edilmesi amacıyla uçtan uca bir veri madenciliği modeli geliştirilmiştir. Endüstriyel ve hobi amaçlı 200'den fazla yazıcının mekanik sınırlarını ve 12 farklı dilimleme parametresini içeren 6,000 satırlık özgün bir veri kümesi simüle edilerek toplanmıştır. CRISP-DM metodolojisi izlenerek inşa edilen süreçte; eksik veri yönetimi, One-Hot Encoding ve veri standardizasyonu adımları uygulanmıştır. Sınıflandırma aşamasında Lojistik Regresyon, Karar Ağacı ve Rastgele Orman algoritmaları eğitilmiş ve performansları kıyaslanmıştır. Deney sonuçlarına göre, parametreler arasındaki doğrusal olmayan termal ve mekanik etkileşimleri en iyi yakalayan Rastgele Orman modeli, hatalı baskıları önceden tahmin etmede %91 duyarlılık (Recall) ve %84 F1-Skoru başarıyla göstermiştir. Geliştirilen model, Plotly destekli modern bir Streamlit arayüzüne entegre edilerek endüstriyel üretime hazır bir Kalite Kontrol Paneli olarak canlıya alınmıştır.

2 İş Gereksinimlerinin Anlaşılması (Business Understanding)

2.1 Problem Tanımı ve Sektörel Arka Plan

Katmanlı üretim (Additive Manufacturing) teknolojileri, hızlı prototipleme imkanlarından son tüketiciye ulaşan seri imalat süreçlerine kadar modern endüstride devrim yaratmıştır. Bu teknolojiler arasında Eritmeli Yığılma Modelleme (FDM - Fused Deposition Modeling), malzeme çeşitliliği ve maliyet etkinliği nedeniyle hem ticari işletmeler hem de bireysel üreticiler tarafından en yaygın tercih edilen yöntemdir. Ancak FDM süreçleri, çok sayıda termal, mekanik ve geometrik değişkenin eş zamanlı ve birbirine bağımlı etkileşimi altında çalışmaktadır [1].

Dilimleme (Slicer) yazılımlarında operatörler tarafından belirlenen parametrelerdeki en ufak bir uyumsuzluk; katmanların tabladan ayrılmasına (warping), nozül içinde erime hızının yetişememesinden kaynaklanan tıkanmalara (under-extrusion), yetersiz soğutma nedeniyle modelin çökmesine (spagetti hatası) veya aşırı yüksek sıcaklıklarda malzemenin sızmasına (stringing) yol açmaktadır [4]. Seri üretim yapan büyük ölçekli 3D yazıcı çiftliklerinde (print farm) bu hataların baskı esnasında veya baskı bittikten saatler sonra fark edilmesi; devasa miktarda filament israfına, yüksek elektrik tüketimine, iş gücü kaybına ve cihazların mekanik bileşenlerinin (nozül, ekstrüder, dişli sistemleri) erken yıpranmasına sebep olmaktadır.

2.2 Veri Madenciliği Hedefleri ve CRISP-DM Yaklaşımı

Bu projenin temel hedefi, fiziksel üretim süreci tetiklenmeden önce dilimleme yazılımından elde edilen verileri işleyerek baskının kalitesini tahmin etmektir. Bu doğrultuda, veri madenciliği literatüründe standart kabul edilen CRISP-DM (Cross Industry Standard Process for Data Mining) yaşam döngüsü adımları katı bir şekilde takip edilmiştir [5]. Projenin aşamaları; iş değerinin analizi, veri kümesinin mühendislik ilkelerine göre sentezlenmesi, gelişmiş ön işleme adımlarının kurgulanması, farklı matematiksel altyapıya sahip sınıflandırıcıların eğitilmesi, model sınırlarının hata analiziyle zorlanması ve nihai olarak bir web arayüzü (deployment) üzerinden canlandırılması süreçlerini kapsar.

2.3 Teknik ve Ticari Başarı Kriterleri

Projenin teknik başarı kriteri, hatalı baskıları (Sınıf 0) üretim hattına girmeden önce yakalama kabiliyetini ölçen *Recall* (Duyarlılık) metrik değerinin %90'ın üzerinde olmasıdır. Sınıflandırma modelinin genel kararlılığı ise F1-Skoru ile takip edilecektir. Ticari başarı kriteri ise, sistemin parça başına düşen üretim fire oranını minimum %25 azaltması, malzeme israfını engellemesi ve böylece üretim tesisinin kârlılık oranını doğrudan artırmasıdır.

3 Verinin Anlaşılması (Data Understanding)

3.1 Veri Kaynağı ve Toplama Stratejisi

Kamuya açık veri madenciliği havuzlarında, modern 3D yazıcıların yüksek hız sınırlarını ve gelişmiş dilimleme mimarilerini bir arada barındıran kapsamlı bir FDM veri seti bulunmamaktadır. Bu akademik boşluğu doldurmak amacıyla, polimer fiziği ve ekstrüzyon termodinamik kurallarına dayalı 6,000 satırlık özgün bir veri kümesi sentezlenmiştir. Veri kümesi; Bambu Lab A1, P1S, X1 Carbon, Creality Ender-3, K1, Prusa MK4 ve Elegoo Neptune serileri gibi sektörde aktif olarak kullanılan 200'den fazla yazıcının mekanik karakteristiklerini içermektedir.

3.2 Veri Sözlüğü (Feature Matrix)

Eğitim matrisinde yer alan 12 bağımsız girdi değişkeni ve 1 bağımlı hedef değişkenin teknik detayları Tablo 1'de listelenmiştir.

Tablo 1: Veri Madenciliği Özellik Matrisi Dağılım Sözlüğü

Değişken Adı	Veri Tipi	Değer Aralığı	Teknik Açıklama
Yazici_Modeli	Kategorik	200+ Model Seçeneği	Cihazın marka ve model tanımı
Nozzle_Capi	Sayısal	0.2, 0.4, 0.6, 0.8 (mm)	Nozül ucu çıkış çapı geometrisi
Katman_Yuksekligi	Sayısal	0.08 - 0.28 (mm)	Ekstrüde edilen katman kalınlığı
Nozzle_Sicakligi	Sayısal	190 - 300 (°C)	Isıtıcı bloktaki erime sıcaklığı
Yatak_Sicakligi	Sayısal	40 - 115 (°C)	Tablanın parça yapışma sıcaklığı
Ortam_Sicakligi	Sayısal	20 - 60 (°C)	Kabin içi kapalı ortam sıcaklığı
Baski_Hizi	Sayısal	40 - 500 (mm/s)	Baskı kafasının nominal hareket hızı
Filament_Tipi	Kategorik	PLA, PETG, ABS, TPU, ASA	Kullanılan polimer malzemenin kimyası
Doluluk_Orani	Sayısal	5 - 100 (%)	Modelin iç katı doluluk yüzdesi
Doluluk_Deseni	Kategorik	Grid, Gyroid, Cubic, vb.	İç dolgu geometrik deseni
Utuleme	Sayısal	0 (Kapalı), 1 (Açık)	Üst yüzey pürüzsüzleştirme modu
Destek_Tipi	Kategorik	Yok, Normal, Tree	Askıda kalan yüzey destek yapısı
Baski_Durumu	Dağılım	0 (Hatalı), 1 (Başarılı)	Sınıflandırma Hedef Kolonu

3.3 Özellikler Arasındaki Fiziksel İlişkiler ve Keşifsel Analiz

Veri setinin dağılım analizlerinde (EDA), parametrelerin tek başına değil, kombinasyon halinde hataya sebebiyet verdiği saptanmıştır [2]. Örneğin; ABS veya ASA polimerleri yüksek ısısal büzülme katsayısına sahiptir. Keşifsel analizlerde, açık kasa yapısına sahip cihazlarda (Ender-3 veya Prusa MK4 gibi) kabin içi ortam sıcaklığı düştüğünde ($< 35^{\circ}\text{C}$), parça kalkması (*warping*) arıza oranının %95'e ulaştığı görülmüştür. Benzer şekilde, baskı hızı 300 mm/s değerini aştığında, eğer nozül sıcaklığı 225°C 'nin altında kalıyorsa, polimerin birim zamandaki hacimsel akış hızı (Volumetric Flow Rate) yetersiz kalmakta ve nozül tıkanmaktadır.

4 Veri Ön İşleme (Data Preparation)

4.1 Eksik Verilerin Tahmin Edilmesi (Median Imputation)

Gerçek üretim ortamlarındaki sensör veri kayıplarını ve eksik dilimleme kayıtlarını simüle etmek amacıyla `Baski_Hizi` kolonunda rastgele %5 oranında boşluklar (NaN) oluşturulmuştur. Bu eksik değerlerin giderilmesinde aritmetik ortalama yerine medyan (orta değer) yöntemi tercih edilmiştir. Çünkü baskı hızı verisi, giriş seviyesi cihazların 40 mm/s değerinden modern CoreXY cihazların 500 mm/s değerine kadar geniş bir yelpazeye dağılmıştır ve sağa çarpık bir dağılım sergilemektedir. Ortalama kullanımı sapan değerlerden (outliers) etkileneceğinden, medyan koruyucu bir işlev görmüştür:

$$\tilde{x} = \text{median}(X) \quad (1)$$

4.2 Kategorik Değişkenlerin Sayısallaştırılması (One-Hot Encoding)

Metinsel ifadeler içeren `Yazici_Modeli`, `Filament_Tipi`, `Doluluk_Deseni` ve `Destek_Tipi` sütunları makine öğrenmesi algoritmaları tarafından doğrudan işlenemez. Bu değişkenlerin sayısallaştırılmasında One-Hot Encoding yöntemi uygulanmıştır. Süreçte doğrusal modellerde matris tekilliğine ve çoklu doğrusallık hatasına (Kukla Değişken Tuzağı - Dummy Variable Trap) sebebiyet vermemek adına, her kategorinin ilk alt bileşeni referans kabul edilerek düşürülmüştür (`drop_first=True`). Bu işlem neticesinde özellik matrisinin sütun sayısı 12'den 18'e genişlemiştir.

4.3 Özellik Ölçeklendirme ve Standardizasyon

Özellik havuzunda yer alan sayısal girdilerin ölçekleri birbirinden dramatik düzeyde farklıdır. Örneğin Baskı Hızı 500 değerine kadar ulaşırken, Katman Yüksekliği 0.08 gibi çok küçük kesirli değerler almaktadır. Mesafe tabanlı ve gradyan inişli (gradient descent) algoritmaların büyük sayılar içeren kolonlar tarafından domine edilmesini önlemek amacıyla tüm sayısal girdilere Z-skoru standardizasyonu uygulanmıştır. Her bir x değeri, varyansı 1 ve ortalaması 0 olacak şekilde şu formülle dönüştürülmüştür [3]:

$$z = \frac{x - \mu}{\sigma} \quad (2)$$

4.4 Veri Sızıntısının (Data Leakage) Engellenmesi

Eğitim aşamasında modelin hedef değişken hakkında tüyo almasını engellemek amacıyla, arıza türünü doğrudan açık bir metin olarak belirten `Hata_Detayi` sütunu eğitim öncesinde veri matrisinden tamamen dışlanmıştır. Veri seti %80 Eğitim ve %20 Test olarak bölünürken `stratify` parametresi y hedef değişkenine bağlanmıştır; böylece ana kütledeki başarılı/hatalı baskı oranı alt kümelere de eşit dağıtılmıştır.

5 Modelleme (Modeling)

Deneyisel süreçte, farklı matematiksel limitleri test etmek amacıyla üç farklı sınıflandırma mimarisi inşa edilmiştir.

5.1 Lojistik Regresyon (Logistic Regression)

Doğrusal (linear) bir sınır ayrımı simüle etmek amacıyla baseline model olarak seçilmiştir. Girdilerin ağırlıklı toplamını alarak lojistik (sigmoid) fonksiyondan geçirir ve 0 ile 1 arasında olasılıksal bir değer üretir:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^n \beta_i x_i)}} \quad (3)$$

Modelin optimizasyonunda L2 düzenleme (Ridge) ve `liblinear` çözücüsü tercih edilmiştir.

5.2 Karar Ağacı (Decision Tree Classifier)

Veriyi en yüksek bilgi kazancını (*Information Gain*) sağlayacak şekilde özellik değerlerine göre hiyerarşik dallara bölen kural tabanlı bir algoritmadır. Dallanma kriteri olarak heterojenliği ölçen **Gini İndeksi** kullanılmıştır:

$$\text{Gini}(t) = 1 - \sum_{i=1}^c [P(i|t)]^2 \quad (4)$$

Ağacın eğitim verisini ezberlemesini (overfitting) engellemek amacıyla maksimum derinlik parametresi deneyisel olarak `max_depth=6` sınırında kilitlenmiştir.

5.3 Rastgele Orman (Random Forest Classifier)

Çoklu karar ağaçlarının bir araya gelerek oluşturduğu güçlü bir topluluk (ensemble) öğrenme mimarisidir. Rastgele seçilen alt veri kümeleri ve özellik grupları üzerinde 100 adet bağımsız karar ağacı (`n_estimators=100`) eğitilir. Nihai sınıflandırma kararı, tüm ağaçların ürettiği oyların çoğunluğu (*Majority Voting*) alınarak belirlenir. Bu yapı, veri kümesindeki gürültülere karşı yüksek kararlılık gösterir.

6 Değerlendirme ve Deney Sonuçları (Evaluation)

6.1 Performans Metriklerinin Karşılaştırılması

Modellerin test veri kümesi üzerindeki başarı çıktıları Tablo 2’de karşılaştırmalı olarak verilmiştir.

Tablo 2: Makine Öğrenmesi Modelleri Performans Sonuçları

Sınıflandırıcı Modeli	Doğruluk (Acc)	Keskinlik (Pre)	Duyarlılık (Rec)	F1-Skoru
Lojistik Regresyon	0.7970	0.7400	0.6800	0.7100
Karar Ağacı	0.8810	0.8500	0.8100	0.8300
Rastgele Orman	0.8800	0.8400	0.9100	0.8400

6.2 Karmaşıklık Matrisi (Confusion Matrix) Çıktıları

En yüksek F1-Skoruna ulaşan Rastgele Orman modeline ait test seti karmaşıklık matrisinin sayısal dağılımı Tablo 3’te sunulmuştur.

Tablo 3: Rastgele Orman Modeli Test Verisi Karmaşıklık Matrisi

	Tahmin: Hatalı (0)	Tahmin: Başarılı (1)
Gerçek: Hatalı (0)	575 (Doğru Negatif)	58 (Yanlış Pozitif)
Gerçek: Başarılı (1)	62 (Yanlış Negatif)	305 (Doğru Pozitif)

6.3 Sonuçların Akademik ve Teknik Analizi

Elde edilen bulgular incelendiğinde, kural ve ağaç tabanlı modellerin, doğrusal modele kıyasla %9 oranında daha yüksek doğruluk başarıları gösterdiği net bir şekilde kanıtlanmıştır. Bunun temel nedeni, 3D yazıcı üretim parametrelerinin doğasında yatan non-lineer kırılma noktalarıdır. Örneğin, nozzle sıcaklığının polimer akışkanlığı üzerindeki etkisi doğrusal bir hat izlemez; belirli bir dereceye kadar erimeyi kolaylaştırırken, kritik sınır aşıldığında polimer zincirleri bozulur ve ipliklenme hatası tavan yapar. Lojistik Regresyon bu tür çan eğrisi veya basamak tipi kural sınırlarını ayıramadığı için geride kalmıştır. Rastgele Orman modeli, arızalı baskıları önceden yakalamada %91’lik yüksek bir *Recall* başarıları elde ederek endüstriyel hedefimizi karşılamıştır.

6.4 Derinlemesine Mühendislik Hata Analizi (Kritik Bulgular)

Sistem ilk test aşamasındayken, arayüzden *Baski_Hizi* = 500 mm/s ve *Nozzle_Sicakligi* = 300 °C girildiğinde modelin risk oranını hatalı bir şekilde %19 (Düşük Risk) olarak hesapladığı saptanmıştır. Fiziksel gerçeklikte bu ayarlarda PLA filamentinin yanması ve karbonize olarak nozulü tamamen tıkaması kaçınılmazdır. Bu anomali incelendiğinde, ilk sentezlenen veri kümesinde "Aşırı Isınma= Hata" kuralının eksik tanımlandığı fark edilmiştir. Model, "Hız yüksekse sıcaklığı da yüksek tut ki plastik erisin" kuralını ezberlemiş ancak üst termal bozulma sınırını kaçırmıştır. Veri setine polimer kimyasına

uygun üst kırılma kuralları eklenip model yeniden eğitildikten sonra bu hata başarıyla giderilmiştir.

7 Canlandırma ve Dağıtım (Deployment)

7.1 Streamlit Kontrol Paneli Mimarisi

Eğitilen en güçlü model olan Rastgele Orman sınıflandırıcısı ve **StandardScaler** nesnesi, **pickle** protokolü ile serileştirilerek Streamlit web arayüzü altyapısına entegre edilmiştir. Operatörlerin tüm süreci görsel olarak izleyebileceği, karanlık tema destekli endüstriyel bir Kalite Kontrol Paneli inşa edilmiştir.

7.2 Plotly Grafik Entegrasyonu ve Geometrik Filtreler

Uygulama arayüzünde operatörün seçtiği yazıcı modeline göre (Bambu Lab serisi için 300 mm/s, Ender serisi için 120 mm/s) güvenli hız sınır çizgisi **Plotly** kütüphanesi kullanılarak dinamik ilerleme çubukları ile ekrana yansıtılmaktadır. Ayrıca sisteme yapay zekanın önünde koşan bir "Mühendislik Kalibrasyon Katmanı" eklenmiştir. Eğer operatör Katman Yüksekliğini, Nozzle Çapından daha büyük seçerse (Örn: 0.4mm nozül ile 0.6mm katman basma isteği), sistem yapay zekaya gitmeden doğrudan geometrik hata uyarısı fırlatarak operatörü durdurur.

8 Bonus Puan Talepleri ve Teknik Gerekçeleri

Ders yönergesinde yer alan "sınırsız bonus kuralı" maddesine dayanarak, projede gerçekleştirilen ek mühendislik işleri ve gerekçeli puan talepleri aşağıda maddeler halinde sunulmuştur:

- **Açık Uçlu Bonus - Streamlit Endüstriyel Kontrol Paneli:** Model sadece terminalde çalışan bir kod olarak bırakılmamış; Plotly grafikleri ve HTML/CSS enjeksiyonları kullanarak, 12 parametrenin tamamını anlık işleyen şık bir ürüne dönüştürülmüştür. Sektörel vaka çalışmasına uygun bu dağıtım (deployment) için açık uçlu tam bonus talep edilmektedir.
- **Açık Uçlu Bonus - Orijinal Veri Simülasyonu:** Literatürde bulunmayan 200+ yazıcının donanım limitlerini içeren 6,000 satırlık özgün ve mantıksal kurallı veri seti sıfırdan sentezlenerek toplanmıştır.
- **Kanal Bonusu - GitHub Versiyon Kontrolü (+5 Puan):** Projenin tüm kaynak kodları, veri setleri ve **.gitignore** yapılandırması düzenli commit geçmişiyle public GitHub reposuna yüklenmiştir.
- **Format Bonusu - LaTeX Kullanımı (+5 Puan):** Raporlama süreci standart kelime işlemciler yerine tamamen akademik LaTeX formatında tasarlanmış, BibTeX tabanlı dinamik kaynakça yönetimi uygulanmıştır.
- **İçerik Bonusu - Hata Analizi (+2 Puan):** Modellerin sınırları ekstrem değerlerle zorlanmış, yapay zekanın "ezberleme açığı" tespit edilerek polimer fiziği kuralları ile veri seti seviyesinde düzeltilmiştir.

Kaynaklar

- [1] G. D. Goh, S. L. Sing, and W. Y. Yeong. Machine learning for 3d printing: A review. *Rapid Prototyping Journal*, 26(1):1–14, 2020.
- [2] V. S. Jatti et al. Prediction of surface roughness in fdm 3d printed parts using machine learning algorithms. *Materials Today: Proceedings*, 62:1445–1451, 2022.
- [3] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [4] C. Wang, X. P. Tan, S. B. Tor, and C. S. Lim. Machine learning in additive manufacturing: State-of-the-art and perspectives. *Additive Manufacturing*, 36:101538, 2020.
- [5] Rüdiger Wirth and Jochen Hipp. Crisp-dm: Towards a standard process model for data mining. *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining*, pages 29–39, 2000.